



ESCUELA POLITÉCNICA NACIONAL
FACULTAD DE INGENIERÍA DE SISTEMAS
RECUPERACIÓN DE LA INFORMACIÓN

Integrantes:

- Jorge Bósquez
- Juan Flores
- Mateo Macas

DOCENTE: ING. IVÁN CARRERA

Sistema de Recuperación de Información Multimodal con RAG

Se diseñó e implementó un sistema de recuperación de información multimodal para un catálogo de música digital. El sistema representa cada producto mediante embeddings de texto e imagen generados con OpenCLIP, almacena 70.530 vectores en FAISS y responde consultas conversacionales mediante un flujo RAG con Gemini. La interfaz Streamlit muestra la respuesta, los documentos Top-k, sus portadas y los puntajes de recuperación, garantizando trazabilidad. Además, se incorporaron cuatro funcionalidades de excelencia: re-ranking, expansión de consultas, relevance feedback y memoria conversacional. La evaluación con 23 consultas y qrels binarios reportó Precision@k, Recall@k y NDCG@k, comparando la recuperación base con la variante reordenada por cross-encoder.

1. Corpus y preparación de datos

El corpus corresponde al archivo meta_Digital_Music.jsonl de Amazon Digital Music. Cada línea representa un producto musical e incluye identificador parent_asin, título, artista o sello, descripción, características, categorías, precio, calificación promedio, número de reseñas, detalles técnicos y varias URL de portada.

- Carga en streaming del JSONL para evitar el consumo innecesario de memoria.
- Eliminación de registros sin título o identificador y deduplicación por parent_asin.
- Selección de la mejor imagen disponible y asociación directa con el texto del producto.
- Dos vistas textuales: una corta para CLIP (máximo 300 caracteres) y otra extensa para el contexto del LLM.




Figura 1. Arquitectura general y flujo de indexación/consulta.

2. Arquitectura e implementación

La solución separa el procesamiento offline del flujo online. Durante la indexación se normaliza el corpus, se descargan y cachean las portadas, se generan embeddings y se construye un índice persistente. Durante la consulta se utiliza el mismo espacio vectorial de CLIP para localizar candidatos y luego se genera una respuesta respaldada por evidencias.

Componente	Tecnología / módulo	Función principal
Preparación	data_loader.py	Normaliza campos, descarta duplicados y construye texto de embedding y texto de contexto.
Imágenes	image_utils.py	Descarga con caché y tolera URLs rotas; si una portada falla, el documento permanece indexado solo con texto.
Representación	OpenCLIP ViT-B-32	Genera vectores de 512 dimensiones. La representación documental fusiona texto (0,6) e imagen (0,4) y se normaliza L2.
Base vectorial	FAISS IndexFlatIP	Búsqueda exacta por producto interno; sobre vectores normalizados equivale a similitud coseno.
Re-ranking	MS MARCO MiniLM	Cross-encoder aplicado a los candidatos recuperados; combina 75 % señal textual refinada y 25 % señal CLIP.
Generación	Gemini API	Construye una respuesta usando exclusivamente el contexto recuperado y advierte cuando la evidencia es insuficiente.
Interfaz	Streamlit	Chat, controles de funcionalidades, portadas, Top-k, scores y botones de feedback.

2.1. Pipeline de recuperación y generación

1. La memoria condensa referencias como “ese álbum” en una consulta autocontenida usando hasta cinco turnos previos.
2. La expansión agrega sinónimos, géneros, artistas relacionados o variantes de escritura; si la API falla, existe un diccionario heurístico.
3. OpenCLIP genera el embedding de la consulta y Rocchio puede desplazarlo hacia documentos marcados como relevantes y alejarlo de los marcados como no relevantes.
4. FAISS recupera 20 candidatos por similitud coseno. El cross-encoder reordena y selecciona los cinco documentos finales.
5. Los textos completos de los resultados forman el contexto del RAG. Gemini produce la respuesta y la interfaz presenta las evidencias con sus puntajes.

Decisión de diseño. Se escogió IndexFlatIP porque el volumen de 70.530 documentos permite una búsqueda exacta y reproducible, evitando aproximaciones que podrían ocultar pérdidas de recuperación. Los vectores y metadatos se almacenan por separado, pero conservan alineación posicional y validación al cargar el índice.

3. Recuperación multimodal, RAG y funcionalidades de excelencia

La recuperación es multimodal porque cada producto puede incorporar simultáneamente la semántica del título/descripción y la información visual de la portada. La consulta del usuario se embebe como texto en el mismo espacio de CLIP. Tras el re-ranking, el sistema entrega al modelo generativo bloques con título, artista, calificación, precio, categorías, descripción y detalles, de modo que la respuesta pueda verificarse contra el catálogo.

Funcionalidad	Implementación	Aporte al sistema
Re-ranking (+15)	reranker.py	Refina el orden de los candidatos con cross-encoder; mejora la precisión y la posición de los relevantes.
Query Expansion (+15)	query_expansion.py	Amplía la consulta mediante Gemini o reglas del dominio musical para aumentar cobertura semántica.
Relevance Feedback (+15)	feedback.py	Aplica Rocchio: $q' = 1,0q + 0,6 \cdot \text{promedio}(\text{relevantes}) - 0,4 \cdot \text{promedio}(\text{no relevantes})$.
Memoria conversacional (+15)	memory.py	Convierte preguntas de seguimiento en consultas independientes mediante el historial reciente.

3.1. Transparencia e interfaz

La interfaz evidencia la separación entre recuperación y generación: además de la respuesta del asistente, presenta cada documento recuperado con portada, título, artista, posición, similitud vectorial y logit del cross-encoder. Los controles laterales permiten activar o desactivar cada funcionalidad avanzada y observar su efecto en una misma sesión.




Figura 2. Interfaz conversacional funcionando con Gemini, re-ranking y evidencias multimodales.

Prueba funcional. Ante la consulta “Muéstrame álbumes de Pink Floyd con buenas calificaciones...”, el sistema recuperó productos asociados, mostró portadas y scores, y generó una respuesta basada en el catálogo. Los valores negativos observados en rerank_score son logits crudos del cross-encoder; el orden final utiliza su normalización relativa junto con la similitud CLIP.

4. Evaluación experimental

Se evaluaron 23 consultas: 15 por artista/sello y 8 temáticas por palabra clave. Los qrels son binarios y se generaron programáticamente: coincidencia exacta del artista limpio en el campo estructurado store, o presencia de una keyword en título/descripción. Se calcularon promedios macro para $k = 5, 10$ y 20 sobre el índice completo de 70.530 documentos.

Definiciones: Precision@ k mide la proporción de relevantes entre los k primeros; Recall@ k mide qué fracción del conjunto total relevante fue recuperada; NDCG@ k considera tanto relevancia como posición, penalizando los aciertos ubicados más abajo.

Métrica	CLIP + FAISS	Con re-ranking	Cambio absoluto
P@5	0.548	0.574	+0.026
P@10	0.548	0.591	+0.043
P@20	0.513	0.513	+0.000
R@5	0.034	0.032	-0.002
R@10	0.066	0.068	+0.002
R@20	0.123	0.123	+0.000
NDCG@5	0.547	0.580	+0.032
NDCG@10	0.549	0.589	+0.041
NDCG@20	0.524	0.535	+0.011




Figura 3. Métricas en las que el re-ranking produjo mejoras más claras.

4.1. Análisis de resultados

- Precision@5 subió de 0,548 a 0,574 (+0,026; +4,8 % relativo) y Precision@10 de 0,548 a 0,591 (+0,043; +7,9 %).
- NDCG@5 aumentó de 0,547 a 0,580 y NDCG@10 de 0,549 a 0,589, confirmando un mejor orden de los documentos relevantes en las primeras posiciones.
- En $k=20$ la precisión y el recall permanecieron iguales, porque el re-ranking reordena el mismo conjunto inicial de 20 candidatos; su principal beneficio es priorizar mejor los primeros resultados.
- Recall@5 disminuyó levemente (-0,002), mientras Recall@10 creció (+0,002). El recall absoluto es bajo porque varias consultas tienen decenas o cientos de relevantes y solo se observan 5–20 resultados.

5. Discusión, limitaciones y conclusiones

5.1. Fortalezas

- Integración real de texto e imagen en un único espacio vectorial, con fallback seguro cuando una portada no está disponible.
- Recuperación exacta, trazable y reproducible; el mismo código de búsqueda se utiliza en la interfaz y en la evaluación.
- Interfaz orientada a la inspección de evidencia, no únicamente a la respuesta generada.

- Las cuatro funcionalidades de excelencia están desacopladas y pueden activarse individualmente para comparar su efecto.

5.2. Limitaciones

- Los qrels temáticos se basan en palabras clave y no en juicios humanos; por ello pueden omitir sinónimos o considerar coincidencias superficiales.
- CLIP limita el texto a 77 tokens; se mitiga con una representación breve para recuperación y un contexto más amplio para generación.
- El cross-encoder mejora el orden, pero aumenta latencia y depende de que el documento relevante aparezca dentro de los candidatos FAISS.
- La memoria y el feedback se conservan solo durante la sesión de Streamlit; no existe persistencia por usuario.
- La generación depende de una API externa y de la disponibilidad del modelo configurado, aunque la recuperación y las evidencias continúan funcionando ante fallos.

5.3. Conclusiones

Los resultados muestran que el re-ranking aporta valor principalmente en las posiciones superiores, elevando la precisión y NDCG sin alterar el conjunto recuperado a $k=20$. La arquitectura modular permite reemplazar modelos, modificar pesos de fusión y ampliar la evaluación sin alterar el flujo completo. Como trabajo futuro se recomienda crear qrels con anotación humana, medir latencia, evaluar consultas en español e inglés por separado y persistir la memoria/feedback entre sesiones.

5.4. Matriz de cumplimiento

Requisito del proyecto	Evidencia implementada
Corpus multimodal	Texto normalizado y portadas asociadas; fallback cuando la imagen no está disponible.
Embeddings CLIP	OpenCLIP ViT-B-32, 512 dimensiones y fusión ponderada texto-imagen.
Base vectorial y Top-k	FAISS IndexFlatIP con 70.530 documentos y similitud coseno exacta.
RAG y evidencias	Gemini genera con contexto recuperado; Streamlit muestra documentos, imágenes y puntajes.
Evaluación	23 consultas, qrels binarios y métricas Precision@k, Recall@k y NDCG@k.
Excelencia	Re-ranking, query expansion, feedback Rocchio y memoria conversacional.

Referencias

- Radford, A. et al. (2021). Learning Transferable Visual Models From Natural Language Supervision. ICML.
- Johnson, J., Douze, M., & Jégou, H. (2019). Billion-scale similarity search with GPUs. IEEE Transactions on Big Data.
- Lewis, P. et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS.
- Nogueira, R., & Cho, K. (2019). Passage Re-ranking with BERT. arXiv:1901.04085.
- Rocchio, J. J. (1971). Relevance Feedback in Information Retrieval. The SMART Retrieval System.